



Réseau de neurones et métaheuristiques pour une prédiction fiable de la production d'énergie photovoltaïque de bâtiments à énergie positive.

03/07/2025

Stagiaires

Saman ISMAIL | Nathan CORREGER | Jad MACHKOUR | Sylvain PERROUAS
A4 FISA Informatique
Promotion 2023 - 2026

Tuteurs

Youssef JOUANE | Simon CAILLARD

Table des matières

Table des matières	<i>Erreur ! Signet non défini.</i>
Table des illustrations	<i>Erreur ! Signet non défini.</i>
1. Introduction	<i>Erreur ! Signet non défini.</i>
2. Contexte	<i>Erreur ! Signet non défini.</i>
3. Revue de l'existant	<i>Erreur ! Signet non défini.</i>
3.1. Premiers travaux sur les réseaux de neurones appliqués à la production PV	Erreur ! Signet non défini.
3.2. Introduction des ConvLSTM et structuration temporelle des données	Erreur ! Signet non défini.
3.3. Optimisation des hyperparamètres par métaheuristiques ..	Erreur ! Signet non défini.
3.4. Résultats observés	Erreur ! Signet non défini.
4. État de l'art et fondements théoriques	<i>Erreur ! Signet non défini.</i>
4.1. Optimisation énergétique des systèmes BIPV à l'aide des métaheuristiques	Erreur ! Signet non défini.
4.2. Métaheuristiques appliquées à différentes phases du cycle de vie BIPV	Erreur ! Signet non défini.
4.2.1. Conception et dimensionnement des panneaux....	Erreur ! Signet non défini.
4.2.2. Optimisation de la production et du suivi MPPT....	Erreur ! Signet non défini.
4.2.3. Estimation des paramètres des modèles PV	Erreur ! Signet non défini.
4.2.4. Applications aux systèmes hybrides et à l'échelle du bâtiment.	Erreur ! Signet non défini.
5. Propositions de solutions	<i>Erreur ! Signet non défini.</i>
5.1. Stratégie de réduction des données	Erreur ! Signet non défini.
5.1.1. Découpage par bâtiments	Erreur ! Signet non défini.
5.1.2. Semaine représentative	Erreur ! Signet non défini.

5.1.3. Supprimer une ligne sur deux.....	Erreur ! Signet non défini.
5.1.4. Réduction par corrélation	Erreur ! Signet non défini.
6. Mise en œuvre	Erreur ! Signet non défini.
6.1. Environnement de calcul	Erreur ! Signet non défini.
6.2. Organisation des tests	Erreur ! Signet non défini.
6.3. Environnement de développement	Erreur ! Signet non défini.
6.4. Versionnage et sauvegarde	Erreur ! Signet non défini.
7. Résultats et analyse	Erreur ! Signet non défini.
7.1. Résultats de la stratégie de réduction des données	Erreur ! Signet non défini.
7.1.1. Découpage par bâtiments	Erreur ! Signet non défini.
7.1.2. Semaine représentative	Erreur ! Signet non défini.
7.1.3. Supprimer une ligne sur deux.....	Erreur ! Signet non défini.
7.1.4. Réduction par corrélation	Erreur ! Signet non défini.
7.2. Comparaison des modèles selon le coefficient R^2	Erreur ! Signet non défini.
7.3. Performance du meilleur modèle	Erreur ! Signet non défini.
7.4. Optimisation des hyperparamètres avec Optuna	Erreur ! Signet non défini.
7.5. Test du modèle avec hyperparamètres fixés....	Erreur ! Signet non défini.
7.6. Analyse statistique des erreurs	Erreur ! Signet non défini.
7.7. Analyse par bâtiment	Erreur ! Signet non défini.
7.8. Résultat en supprimant le bâtiment 5.....	Erreur ! Signet non défini.
8. Conclusion et perspectives	Erreur ! Signet non défini.
Glossaire	Erreur ! Signet non défini.
Bibliographie	Erreur ! Signet non défini.

Table des illustrations

Figure 1 - Comparaison des résultats par bâtiment	16
Figure 2 - R^2 pour les différents modèles.....	18
Figure 3 - R^2 sur données réduites.....	19
Figure 4 - Superposition des valeurs réel et prédite.....	19
Figure 5 - Valeurs prédites en fonction des valeurs réel.....	20
Figure 6 - Evolution du MAE en fonction des essais.....	21
Figure 7 - Visualisation du modèle sur HP fix.....	22
Figure 8 - Superposition des valeurs réel et prédite pour le bâtiment 3	23
Figure 9 - Superposition des valeurs réel et prédite pour le bâtiment 5	23
Figure 10 - Histogramme des erreurs par bâtiment	24

1. Introduction

La transition énergétique actuelle pousse de nombreux secteurs, et notamment celui du bâtiment, à adopter des stratégies de production et de consommation d'énergie plus durables. Dans ce contexte, les bâtiments à énergie positive (BEPOS), capables de produire plus d'énergie qu'ils n'en consomment sur une période donnée, occupent une place centrale. Parmi les technologies favorisant ce type de bâtiment, les systèmes photovoltaïques (PV) intégrés jouent un rôle de premier plan.

La prédiction précise de la production énergétique des panneaux photovoltaïques est un enjeu clé. Elle permet non seulement d'optimiser l'autoconsommation et le stockage, mais aussi d'améliorer l'intégration des énergies renouvelables dans le réseau électrique. Toutefois, cette prévision reste complexe, en raison de la variabilité des conditions météorologiques et de la multiplicité des facteurs influençant la performance des systèmes PV (orientation des panneaux, conditions d'ensoleillement, température ambiante, etc.).

Les méthodes traditionnelles de prévision reposaient sur des approches statistiques ou physiques. Aujourd'hui, l'essor de l'intelligence artificielle, et plus particulièrement de l'apprentissage profond offre de nouvelles perspectives pour la modélisation de séries temporelles telle que la production énergétique PV. Parmi ces modèles, le réseau de neurones ConvLSTM (Convolutional Long Short-Term Memory) s'avère adapté pour capter à la fois les dynamiques temporelles et les structures spatiales des données.

Cependant, la performance d'un modèle de l'apprentissage profond dépend fortement de ses hyperparamètres. Le choix optimal du taux d'apprentissage, du nombre de neurones, des tailles de filtres, ou encore du batch size influence grandement la précision des prédictions. Trouver ces hyperparamètres de manière manuelle est fastidieux et inefficace, d'où l'intérêt croissant pour les approches automatiques d'optimisation.

Dans ce projet, nous explorons l'application de métaheuristiques des algorithmes inspirés de phénomènes naturels pour optimiser les hyperparamètres du modèle ConvLSTM. Plus spécifiquement, nous avons expérimenté l'algorithme Optuna reposant sur l'optimisation bayésienne.

L'objectif de ce travail est de démontrer que l'optimisation par métaheuristiques permet d'améliorer significativement la précision de la prévision de la production énergétique PV, et de poser les bases pour des outils de prédiction plus fiables et robustes à destination des bâtiments à énergie positive.

Ce rapport présente la démarche suivie : après avoir introduit le contexte et les fondements théoriques, nous détaillons l'état de l'art sur les méthodes utilisées, exposons nos propositions de solutions et la méthodologie mise en œuvre, avant d'analyser les résultats obtenus et d'ouvrir sur les perspectives de ce travail.

2. Contexte

Dans le cadre de la transition énergétique et du développement des bâtiments à énergie positive (BEPOS), plusieurs installations photovoltaïques ont été mises en place sur différents bâtiments, répartis dans diverses régions, notamment à Strasbourg. Ces bâtiments, aux caractéristiques physiques variées (longueur, largeur, orientation, inclinaison), sont équipés de capteurs et de systèmes de mesure qui enregistrent en continu leur production énergétique ainsi que des données environnementales associées.

Les données recueillies comprennent, pour chaque bâtiment, des variables telles que la géolocalisation (latitude, longitude), des paramètres physiques, mais aussi des informations météorologiques détaillées (irradiance, température, humidité, vent, etc.) et temporelles comme la date. L'ensemble de ces données constitue un jeu riche, multidimensionnel et hétérogène, propre à chaque site.

Ce corpus de données constitue le corps de l'apprentissage de modèles d'intelligence artificielle capables de modéliser le comportement de la production solaire dans le temps. En effet, grâce à l'historique de production et aux données explicatives disponibles, il est possible d'entraîner des modèles de prédiction qui anticipent la production énergétique future à court terme (journalier, hebdomadaire, etc.).

L'objectif est d'optimiser ces modèles en ajustant automatiquement leurs hyperparamètres, afin d'en maximiser la précision prédictive. Cette étape vise à identifier les configurations les plus performantes (par exemple : nombre de filtres, taille des kernels, taux d'apprentissage, batch size, etc.) en fonction des spécificités des données. Elle s'effectue grâce à des méthodes d'optimisation dites métaheuristiques, inspirées de processus naturels (essaims, génétique, recherche bayésienne, etc.), qui explorent l'espace des paramètres de manière efficace.

3. Revue de l'existant

Depuis plusieurs années, ce projet s'inscrit dans une démarche progressive visant à améliorer la précision de la prévision de la production photovoltaïque dans les bâtiments à énergie positive. Plusieurs groupes d'élèves-ingénieurs et enseignants chercheurs ont contribué à ce travail par étapes, en explorant différentes configurations de modèles d'intelligence artificielle et d'algorithmes d'optimisation.

3.1. Premiers travaux sur les réseaux de neurones appliqués à la production PV

Dans un premier temps, les modèles utilisés étaient des réseaux de neurones classiques (MLP) ou récurrents simples (RNN, LSTM). Ces architectures ont montré des capacités intéressantes à modéliser des séries temporelles, mais leurs limites sont apparues pour capturer à la fois la dynamique temporelle et les variations périodiques, notamment saisonnières et hebdomadaires.

Ces premières versions utilisaient des structures de données assez simples, et les hyperparamètres étaient définis manuellement ou par recherche en grille, ce qui limitait l'efficacité des modèles et leur capacité de généralisation.

3.2. Introduction des ConvLSTM et structuration temporelle des données

L'un des apports majeurs des groupes précédents fut l'introduction du modèle ConvLSTM, plus adapté à la modélisation spatio-temporelle. Ce modèle a été exploité dans le rapport de recherche de Chayma Mabrouk, Yacine Hocine, Paul-Émile Escande et Thomas Duflaut (2024), qui constitue une avancée structurante dans le cadre du projet.

Ce groupe a proposé une structuration innovante des données sous forme de matrices temporelles (par exemple, jours $\times$ mois ou semaines $\times$ années), permettant au modèle ConvLSTM de traiter les séries temporelles comme des séquences d'« images temporelles ». Cette approche a permis d'améliorer la qualité des prédictions par rapport aux modèles LSTM classiques.

3.3. Optimisation des hyperparamètres par métaheuristiques

Une autre contribution clé a été l'intégration d'approches d'optimisation automatique des hyperparamètres pour le ConvLSTM, via trois stratégies principales :

- **PSO (Particle Swarm Optimization)** : utilisé pour ajuster les filtres, tailles de kernels, taux d'apprentissage, etc., avec environ 50 essais.
- **Optuna** : plateforme d'optimisation bayésienne permettant des essais dynamiques avec arrêt anticipé et visualisation de l'importance des hyperparamètres.
- **Algorithme Génétique (AG)** : utilisé avec un encodage discret des hyperparamètres, croisement mono-point et mutations aléatoires.

Chaque méthode a été testée dans des conditions expérimentales comparables, avec une attention particulière à la séparation entraînement/validation/test et à l'absence de fuite de données.

3.4. Résultats observés

Les résultats ont montré une amélioration significative par rapport au modèle de référence (non optimisé) :

- Le modèle ConvLSTM + AG a atteint un $R^2 \approx 0.91$ et une MAE ≈ 3.1 , contre $R^2 \approx 0.82$ et MAE ≈ 5.0 pour le modèle Baseline.
- Le PSO et Optuna ont donné des performances proches (R^2 de 0.88 à 0.90), mais avec des comportements d'optimisation différents.
- L'AG s'est révélé plus coûteux en temps de calcul mais plus performant en qualité prédictive.

L'analyse des résultats a mis en lumière l'importance des hyperparamètres suivants :

- le taux d'apprentissage,
- le nombre de filtres,
- la taille du kernel,
- le batch size.

L'étude a également souligné la sensibilité du modèle aux représentations temporelles des données, ce qui justifie la diversification des formats d'entrée (matrices jour/mois, semaine/année...).

4. État de l'art et fondements théoriques

4.1. Optimisation énergétique des systèmes BIPV à l'aide des métaheuristiques

Les systèmes photovoltaïques intégrés au bâti (BIPV) constituent une solution technologique prometteuse dans le cadre de la transition énergétique. En alliant production d'énergie renouvelable et intégration architecturale, ils participent à l'émergence de bâtiments à faible empreinte carbone, voire à énergie positive. Toutefois, maximiser leur performance énergétique demeure un défi multidimensionnel. En effet, la configuration optimale d'un système BIPV dépend de nombreux paramètres interdépendants : orientation, inclinaison, surface disponible, interactions avec l'environnement urbain (ombrage, albédo), profil de charge du bâtiment, mais aussi intégration éventuelle de systèmes de stockage.

Ces problématiques d'optimisation, souvent non linéaires, fortement contraintes et à objectifs multiples (énergie, coût, émissions, confort), ne se prêtent pas aisément aux méthodes exactes classiques. C'est dans ce contexte que les métaheuristiques s'imposent comme des outils puissants pour explorer efficacement de vastes espaces de recherche. Leur flexibilité algorithmique et leur capacité à s'adapter à des contextes variés en font des candidats sérieux pour la modélisation, le dimensionnement et le pilotage des systèmes BIPV.

4.2. Métaheuristiques appliquées à différentes phases du cycle de vie BIPV

4.2.1. Conception et dimensionnement des panneaux

Benzaoui et al. (2023, *Renewable and Sustainable Energy Reviews*) utilisent l'Artificial Bee Colony (ABC) pour optimiser l'orientation, la production et la température des façades. L'algorithme converge plus rapidement que PSO ou NSGA-II, mais son application reste limitée aux façades verticales.

Chen et al. (2024, *Applied Energy*) emploient NSGA-III pour optimiser simultanément l'orientation, l'inclinaison et la surface des panneaux dans des environnements urbains complexes. L'approche intègre les ombrages dynamiques et un bilan économique (valeur actuelle nette, temps de retour sur investissement). Toutefois, le temps de simulation est élevé et aucune évaluation environnementale n'est intégrée.

Khan et al. (2025, *IEEE Transactions on Sustainable Energy*) proposent un algorithme hybride PSO–GA pour dimensionner un système BIPV avec batterie. Ils observent une réduction de 22 % de l'énergie importée depuis le réseau.

Cependant, la reproductibilité est peu détaillée, et l'impact environnemental du système n'est pas analysé.

Karbasforoushha et al. (2024, *Journal of Building Engineering*) réalisent une revue exhaustive des métaheuristiques (PSO, GA, memetic, etc.) appliquées à l'optimisation énergétique du bâtiment. Les algorithmes memétiques y sont salués pour leur flexibilité, malgré un coût computationnel souvent élevé.

4.2.2. Optimisation de la production et du suivi MPPT

Yildiz et al. (2023, *Energy Reports*) utilisent le Grey Wolf Optimizer (GWO) pour améliorer le suivi MPPT dans des systèmes BIPV multi-surfaces. Le GWO s'avère particulièrement efficace en conditions d'ombrage partiel et est adapté à des dispositifs embarqués. Il n'intègre cependant pas l'optimisation initiale du dimensionnement.

Mhanni & Lagmich (2024, *EPJ Photovoltaics*) comparent GWO à PSO et au Pelican Optimization Algorithm (POA). Le GWO se montre plus robuste face aux fluctuations d'irradiance, améliorant la stabilité du point de fonctionnement.

Çiriş et al. (2025, *IJESG*) démontrent que PSO, lorsqu'il est correctement paramétré, surpasse la méthode classique P&O pour le suivi MPPT sous ombrage partiel.

4.2.3. Estimation des paramètres des modèles PV

Zga et al. (2025, *PeerJ Computer Science*) comparent dix métaheuristiques novatrices (Crayfish, Golf Optimizer, Growth Optimizer, etc.) pour l'estimation des paramètres de modèles à une, deux ou trois diodes. Le Growth Optimizer s'impose comme le plus performant, combinant vitesse de convergence et précision.

Wulfran et al. (2025, *Scientific Reports*) introduisent le Logarithmic Mean-Based Optimization (LMO). Sur les benchmarks CEC 2017, LMO démontre une excellente stabilité et convergence, puis est appliqué à un système hybride PV-éolien avec succès (rendement élevé pour un coût énergétique modéré).

4.2.4. Applications aux systèmes hybrides et à l'échelle du bâtiment

Güven et al. (2024, *Neural Computing and Applications*) développent un algorithme hybride GWO-Cuckoo Search pour le dimensionnement énergétique d'un campus, intégrant PV, éolien et batteries. L'optimisation vise à réduire les émissions de carbone tout en assurant une autonomie énergétique.

Mhanni et al. (2024, *Energies*) recensent l'usage de PSO, ABC, BAT, Firefly Algorithm et Cuckoo Search pour la réduction de la consommation énergétique dans les bâtiments résidentiels. Les approches hybrides sont plébiscitées pour leur capacité à équilibrer performance énergétique et confort thermique.

Yuan et al. (2022, *Buildings*) appliquent un algorithme POA–SCO (Pelican Optimization + Single Candidate Optimizer) à la réduction de la consommation dans un bâtiment tertiaire simulé via EnergyPlus. Le modèle montre une forte résilience face aux variations climatiques saisonnières.

Les travaux récents consacrés à l'optimisation énergétique des systèmes BIPV à l'aide de métaheuristiques montrent un dynamisme croissant de la recherche dans ce domaine. Que ce soit pour le dimensionnement des installations, la gestion du point de puissance maximale (MPPT), ou encore l'estimation fine des paramètres électriques des modules, les algorithmes évolutifs et bio-inspirés offrent des performances notables en matière de précision, de robustesse et de flexibilité. En particulier, les approches hybrides (telles que PSO-GA, POA-SCO ou GWO-CS) permettent de combiner les atouts de plusieurs paradigmes pour surmonter les limitations individuelles de chaque méthode.

Cependant, plusieurs pistes d'amélioration subsistent. On note encore une faible prise en compte de l'impact environnemental global des solutions optimisées (analyse de cycle de vie, émissions associées aux composants et à l'entraînement des modèles). De même, le coût énergétique des calculs reste rarement quantifié. Enfin, la reproductibilité scientifique pâtit parfois de l'absence de publication des paramètres expérimentaux détaillés.

Dès lors, il semble essentiel, pour les recherches à venir, de concilier performance prédictive, sobriété computationnelle et durabilité environnementale. Cela suppose notamment une approche intégrée, combinant outils d'optimisation, indicateurs environnementaux, et méthodologies d'évaluation multicritère. Une telle démarche contribuerait à inscrire l'optimisation des systèmes BIPV dans une logique systémique, rigoureuse et résolument orientée vers l'ingénierie soutenable.

5. Propositions de solutions

5.1. Stratégie de réduction des données

L'entraînement d'un modèle d'intelligence artificielle, notamment de type LSTM / ConvLSTM, nécessite un volume important de données. Ces données sont utilisées à la fois pour entraîner le modèle et pour réaliser des tests permettant de quantifier la précision du modèle et de ses prédictions.

Dans notre étude, nous disposons, pour chaque bâtiment, d'un ensemble de données regroupées dans le fichier `full_dataset.csv`. Chaque ligne correspond à une journée couvrant la période de 2018 à 2022 et chaque colonne représente

une variable mesurée : température, vent, radiance, etc... Ces données sont conséquentes ~11.000 lignes x 165 colonnes.

Plus le modèle reçoit de données, plus le temps d'entraînement augmente. À l'inverse, une réduction excessive de données peut altérer la qualité des prédictions. L'objectif de la stratégie de réduction de données est donc de trouver un compromis entre performance et temps de calcul : diminuer le volume d'entrée tout en conservant un maximum de précision.

Ce gain de temps peut être mis à profit pour effectuer davantage d'itérations d'entraînement. Ainsi, une IA entraînée sur un dataset réduit mais optimisé pourrait finalement atteindre une meilleure précision qu'une IA entraînée une seule fois sur l'ensemble complet des données.

5.1.1. Découpage par bâtiments

1ère piste de solution : découper et entraîner l'IA par bâtiment.

L'idée ici consiste à scinder le dataset principal en plusieurs sous-ensembles, chacun correspondant à un bâtiment spécifique. L'hypothèse sous-jacente est que chaque bâtiment, ayant des caractéristiques propres (orientation, structure, géolocalisation), pourrait bénéficier d'un modèle spécialisé, mieux adapté à ses particularités.

Cela permettrait également de réduire le volume de données traité par chaque modèle, et donc de diminuer le temps d'entraînement. Chaque modèle apprendrait uniquement à partir de ses données ce qui pourrait améliorer sa précision sur celui-ci.

5.1.2. Semaine représentative

2^e piste de solution : condenser les données en une semaine type.

Cette méthode consiste à résumer un mois complet de données en une seule semaine représentative.

Par exemple, nous calculons la moyenne de chaque variable pour tous les lundis d'un mois, puis utilisons ces moyennes pour représenter un lundi type dans la semaine synthétique.

5.1.3. Supprimer une ligne sur deux

3^{ème} piste de solution : peut-être que l'IA n'a pas besoin de chacune des journées entre 2018 à 2022.

L'idée ici est de tester si la suppression d'une ligne sur deux dans le dataset c'est-à-dire l'élimination d'un jour sur deux a un impact sur la précision du modèle.

5.1.4. Réduction par corrélation

Cette quatrième piste de solution a été explorée à la suite des résultats obtenus avec les approches précédentes.

Pour cela, nous avons généré une matrice de corrélation entre l'ensemble des colonnes du dataset et la colonne "production". Cette matrice nous a permis d'identifier les variables les plus pertinentes à conserver.

L'idée de cette piste est de voir s'il est possible de réduire le nombre de données en réduisant le nombre de colonne. L'objectif est de déterminer le nombre optimal de colonnes permettant d'obtenir le meilleur compromis entre précision des résultats et temps d'exécution.

6. Mise en œuvre

La mise en œuvre technique du projet a été réalisée au sein d'un environnement de calcul mis à disposition par le laboratoire CESI LINEACT. Cette infrastructure, associée à une organisation rigoureuse des tests et à un développement modulaire en Python, a permis de conduire l'ensemble des expérimentations dans des conditions contrôlées et reproductibles.

6.1. Environnement de calcul

L'ensemble des entraînements de modèles, des tests et des visualisations de résultats ont été réalisés sur une machine virtuelle fournie par le CESI. Cette VM disposait des caractéristiques suivantes :

- **Mémoire vive (RAM)** : 32 Go
- **Système d'exploitation** : Linux (distribution Ubuntu)
- **Accès distant** sécurisé via VPN et terminal SSH
- **Stockage partagé** pour les fichiers de données, les modèles et les résultats

Cette configuration a permis d'exécuter des scripts d'apprentissage profond relativement exigeants, bien que le temps d'entraînement restait conséquent pour certains modèles complexes.

6.2. Organisation des tests

Étant donné la durée importante des phases d'entraînement, notamment lors des boucles d'optimisation d'hyperparamètres (PSO, AG, Optuna), les sessions d'exécution étaient programmées de manière stratégique :

- Les tests étaient lancés la nuit afin d'exploiter les ressources de la VM sans interruption et d'obtenir les résultats le matin suivant.
- Les logs, courbes de pertes, images de prédiction et modèles sauvegardés étaient générés automatiquement à la fin de chaque session, facilitant l'analyse a posteriori.
- Un planning de lancement des sessions d'optimisation a été tenu à jour manuellement pour éviter les conflits d'usage de la VM et garantir un suivi méthodique.

6.3. Environnement de développement

Le développement a été effectué principalement via Jupyter Notebook, installé et configuré sur la VM. Ce choix a permis de :

- documenter le code au fil de l'expérimentation,
- visualiser instantanément les résultats (courbes, tableaux),
- faciliter les ajustements progressifs.

Toutes les bibliothèques nécessaires ont été installées dans un environnement Python dédié. Parmi les principales dépendances :

- numpy, pandas pour le traitement des données,
- matplotlib, seaborn pour les visualisations,
- scikit-learn pour les métriques d'évaluation,
- tensorflow / keras pour le modèle ConvLSTM,
- optuna, deap, pyswarms pour les métaheuristiques.

6.4. Versionnage et sauvegarde

Le code source a été versionné sur GitHub, sur un dépôt à l'adresse suivante:
<https://github.com/Sylv111/IR-MetaHeuristics>

Chaque expérimentation importante faisait, dans laquelle les notebooks, les images issues des prédictions, les courbes de performance et les résultats chiffrés étaient poussés depuis la VM.

Cela a permis à l'ensemble des membres du groupe de :

- collaborer efficacement à distance,
- suivre l'historique des changements,
- garantir la traçabilité des résultats et la répliquabilité des expériences.

7. Résultats et analyse

7.1. Résultats de la stratégie de réduction des données

7.1.1. Découpage par bâtiments

Dataset	ConvLSTM			ConvLSTM + OPTUNA		
	MAE	MSE	R ²	MAE optimisé	MSE optimisé	R ² optimisé
batiment_1	9,730	158,857	0,073	9,574	157,290	0,0817
batiment_2	6,667	86,169	0,317	7,391	89,160	0,2934
batiment_3	7,680	130,266	0,168	7,713	134,386	0,1415
batiment_4	14,245	439,083	0,008	11,960	301,564	0,3186
batiment_5	63,381	6823,705	0,243	61,663	6378,276	0,2927
batiment_6	12,884	275,150	0,046	12,710	249,214	0,1355
batiment_7	15,835	381,565	-0,058	15,727	318,141	0,1182
batiment_8	11,330	243,285	0,075	11,717	225,000	0,1443
batiment_9	14,601	360,000	0,075	14,511	330,719	0,1499




Figure 1 - Comparaison des résultats par bâtiment

Les résultats obtenus avec les modèles ConvLSTM, même après optimisation via Optuna, restent globalement peu satisfaisants. Plusieurs bâtiments donne des résultats en R² proche de 0 voir inférieur, suggérant que le modèle prédit moins bien qu'une simple moyenne.

7.1.2. Semaine représentative

Réseau de neurones et métaheuristiques pour une prédiction fiable de la production d'énergie photovoltaïque de bâtiments à énergie positive.

Dataset	MAE	MSE	R ²
dataset_semaine_representative	0,046	0,003	0,029

La méthode de la semaine représentative, qui vise à résumer un mois en une semaine type, donne de mauvais résultats. Le R² est très faible (0,029). Cette réduction fait perdre trop d'information, rendant cette approche peu pertinente pour la prédiction.

7.1.3. Supprimer une ligne sur deux


Dataset	MAE	MSE	R ²
dataset_reduit	0,046	0,003	0,029

L'autre piste explorée a été la réduction du volume de données en supprimant un jour sur deux. Les résultats ont montré que cette approche dégrade les prédictions. Le R² est plutôt bas, indiquant que l'information perdue entre les jours supprimés contenait des éléments importants pour l'apprentissage du modèle.

7.1.4. Réduction par corrélation

Un programme nous a permis de récupérer les colonnes les plus corrélées avec la colonne production.

Voici la visualisation de la corrélation entre la production et les autres variables du jeu de données.



Dans le but de prédire la production, cette analyse permet d'identifier les colonnes les plus pertinentes à fournir à l'IA, en se basant sur leur niveau de corrélation.

Nous avons ensuite testé plusieurs configurations en sélectionnant 15, 20, 30 et 40 colonnes les plus corrélées, afin de trouver le meilleur compromis entre précision (R²) et temps d'exécution. Les résultats sont présentés ci-dessous.

Nombre de colonnes les plus corrélés	Temps d'exécution	R ²
40 colonnes	25 min 12 sec	0,613
30 colonnes	14 min 26 sec	0,701
20 colonnes	11 min 48 sec	0,654
15 colonnes	14 min 10 sec	0,553

Le fichier csv de 30 colonnes offre la meilleure précision avec un R² de 0,701 en réduisant considérablement le temps d'entraînement ~15 minutes.

Nous choisissons donc ce fichier réduit à 30 colonnes comme base pour la suite des tests. Il offre la meilleur précision et un temps de calcul plus court. Parfait pour faire tourner plusieurs heures nos traitement la nuit.

7.2. Comparaison des modèles selon le coefficient R²

Le graphique ci-dessous présente le coefficient de détermination R² obtenu pour différents modèles testés, à la fois sur des données réduites et sur le jeu de données complet :




Figure 2 - R² pour les différents modèles

Le modèle ConvLSTM optimisé avec Optuna se distingue nettement avec un R² de 0.9624 sur les données réduites et 0.8889 sur les données complètes, surpassant tous les autres modèles testés (LSTM, Transformer, ConvLSTM non optimisé). Cela montre que l'optimisation des hyperparamètres peut améliorer la performance prédictive d'un modèle de deep learning.

Voici un récapitulatif de tous les modèles sur les données réduites :




Figure 3 - R² sur données réduites

On observe que ConvLSTM + PSO et ConvLSTM + Optuna sont très proche, néanmoins le temps d'entraînement et d'optimisation avec PSO est plus long que celui avec Optuna. Pour la suite nous avons donc voulu nous concentrer sur Optuna.

7.3. Performance du meilleur modèle

Le modèle ConvLSTM optimisé a été évalué plus finement, comme illustré dans le graphique suivant :




Figure 4 - Superposition des valeurs réel et prédite

La courbe orange (prédictions) épouse bien la courbe bleue (valeurs réelles), avec un MAE de 1.8017, un MSE de 12.4576, et un excellent R^2 de 0.9614. Cette qualité de prédiction est confirmée par le nuage de points suivant :




Figure 5 - Valeurs prédites en fonction des valeurs réel

On observe une forte corrélation entre les valeurs réelles et prédites, avec les points alignés sur la droite rouge $y=x$, témoignant d'une bonne précision du modèle.

7.4. Optimisation des hyperparamètres avec Optuna

L'évolution du MAE au cours des différents essais d'Optuna est illustrée ci-dessous :




Figure 6 - Evolution du MAE en fonction des essais

On constate une variabilité significative entre les essais, montrant qu'il existe plusieurs combinaisons d'hyperparamètres acceptables. L'analyse des meilleurs essais (trials 0 et 10 à 14) a permis de dégager les plages suivantes :

HP	Min	Max	Moyenne	STD	BestValues
<u>lr</u>	0,0041	0,00957	0,00725	0,00216	0,00795
<u>filters1</u>	60	74	65,5	4,8887	67
<u>filters2</u>	103	128	117,83	10,571	112
<u>Dense_units</u>	89	127	115,5	15,436	117

Les valeurs moyennes des hyperparamètres ont ensuite été fixées pour entraîner un modèle plus stable.

7.5. Test du modèle avec hyperparamètres fixés

Le modèle ainsi figé atteint les performances suivantes sur le jeu de données réduites :

MAE : 2.2024

MSE : 14.8233

R^2 : 0.9541

Il a ensuite été enregistré avec la méthode `model.save()` pour être appliqué à de nouvelles données ou au dataset complet. Voici le résultat des prédictions sur l'ensemble des données :




Figure 7 - Visualisation du modèle sur HP fix

Ce visuel n'étant pas très lisible, une analyse par bâtiment sera réalisée ultérieurement.

7.6. Analyse statistique des erreurs

Un résumé statistique des résultats est présenté ci-dessous :

	Réel	Prédite	ErreurAbs
mean	38,4	38,02	2,85
std	55,8	55,4	4,8
min	0,1	-14,9	0,0
25%	6,9	6,6	0,6
50%	23,2	23,2	1,4
75%	40,5	40,3	2,9
max	536,7	483,8	82,9

On observe une erreur absolue moyenne (MAE) de 2.85, ce qui reste faible compte tenu de l'échelle des productions (de 0 à plus de 500). Cependant, la valeur maximale d'erreur atteint 82.96, ce qui justifie une analyse par bâtiment.

7.7. Analyse par bâtiment

Le graphique ci-dessous montre les prédictions spécifiques pour le bâtiment 3 :




Figure 8 - Superposition des valeurs réel et prédite pour le bâtiment 3

La prédiction suit bien la production réelle, avec peu de décalages notables.

Le bâtiment 5 présente suit plutôt bien la production réelle également :




Figure 9 - Superposition des valeurs réel et prédite pour le bâtiment 5

Ce bâtiment affiche une production variant entre 0 et plus de 500, ce qui contraste fortement avec les autres bâtiments (plafonnant autour de 100). Ce

déséquilibre entraîne une dispersion plus forte des erreurs, comme le montre l'histogramme ci-dessous :




Figure 10 - Histogramme des erreurs par bâtiment

On voit clairement que les erreurs du bâtiment 5 (en violet) sont plus larges et plus dispersées, expliquant la plupart des plus grandes erreurs observées sur l'ensemble du dataset.

7.8. Résultat en supprimant le bâtiment 5

Comme nous l'avons vu précédemment, le bâtiment 5 présente une grande variabilité dans les valeurs de production (allant jusqu'à plus de 500), ce qui a un impact significatif sur la qualité des prédictions globales et génère les plus grandes erreurs.

Afin de vérifier cette hypothèse, nous avons entraîné à nouveau le modèle en excluant le bâtiment 5 du jeu de données, puis évalué ses performances.

Résultats obtenus sans le bâtiment 5 :


MAE : 1.6558

MSE : 10.3872

R^2 : 0.9692

Ces résultats montrent une amélioration significative du score R^2 (passant de 0.9541 à 0.9692), ainsi qu'une baisse des erreurs absolue et quadratique. Cela confirme que le bâtiment 5, avec sa dynamique très différente des autres, perturbe l'apprentissage global du modèle.

Pour pousser cette approche plus loin, nous avons choisi d'utiliser seulement les bâtiments situés au niveau de l'Esplanade. Cela nous a permis d'atteindre un R^2 de 0,9843, le meilleur résultat jusqu'à présent. Voici les différentes courbes pour l'illustrer :



8. Conclusion et perspectives

Dans ce travail, nous avons comparé plusieurs architectures de modèles de deep learning pour la prédiction de la production énergétique, en utilisant à la fois des données réduites et des données complètes. Parmi les modèles testés, le ConvLSTM optimisé avec Optuna s'est rapidement imposé comme le plus performant, atteignant un coefficient de détermination R^2 de 0.9624 sur les données réduites et 0.8889 sur les données complètes. Cette performance surpasse largement celles des modèles LSTM, Transformer, ou ConvLSTM non optimisé.

L'optimisation des hyperparamètres via Optuna a montré une grande variabilité entre les essais, mais aussi l'existence de plusieurs combinaisons efficaces. En fixant les hyperparamètres sur leurs valeurs moyennes issues des meilleurs essais, un nouveau modèle a été entraîné, avec des performances très satisfaisantes (MAE : 2.2024, R^2 : 0.9541). Ce modèle a été sauvegardé afin d'être réutilisable sur de nouvelles données.

L'analyse statistique et par bâtiment a mis en évidence que les erreurs les plus importantes provenaient du bâtiment 5, dont les valeurs de production dépassent 500, alors que les autres bâtiments restent généralement en dessous de 110. Ce déséquilibre induit une dispersion plus forte des erreurs pour ce bâtiment, ce qui perturbe l'apprentissage global du modèle.

Afin de valider cette observation, une nouvelle expérimentation a été menée en excluant le bâtiment 5 du dataset. Les résultats sont sans appel :

MAE réduit à 1.6558, MSE à 10.3872 et un R^2 atteignant 0.9692.

Cela confirme que ce bâtiment, en raison de sa dynamique atypique, dégrade la performance globale du modèle.

En conclusion, ce projet a permis de :

Démontrer l'efficacité du modèle ConvLSTM optimisé par Optuna pour la prédiction de production énergétique.

Mettre en évidence l'importance de l'optimisation des hyperparamètres dans l'amélioration des performances.

Souligner la nécessité d'une analyse différenciée par bâtiment, en particulier pour ceux aux comportements extrêmes.

Ces résultats ouvrent la voie à des perspectives intéressantes : entraîner des modèles spécialisés par groupe de bâtiments similaires, ou encore appliquer des techniques de normalisation adaptées aux cas atypiques pour stabiliser les performances globales.

Glossaire

- **Algorithme génétique** : Méthode d'optimisation inspirée de la sélection naturelle, utilisant croisement et mutation pour explorer les solutions.
- **Apprentissage profond** : Technique d'IA utilisant des réseaux de neurones profonds pour apprendre des représentations complexes.

- **Autoconsommation** : Utilisation directe de l'énergie produite localement, sans la réinjecter dans le réseau.
- **Batch size** : Nombre d'échantillons traités en une seule itération lors de l'entraînement du modèle.
- **BEPOS (Bâtiment à énergie positive)** : Bâtiment produisant plus d'énergie qu'il n'en consomme sur une période donnée.
- **ConvLSTM** : Modèle combinant LSTM et convolution, adapté aux données spatio-temporelles.
- **Corrélation** : Lien statistique entre deux variables, utilisé ici pour sélectionner les données pertinentes.
- **Hyperparamètre** : Paramètre défini avant l'apprentissage, influençant les performances du modèle (ex. taux d'apprentissage, nombre de filtres).
- **LSTM** : Type de réseau de neurones récurrents capable de gérer des dépendances temporelles longues.
- **MAE (Mean Absolute Error)** : Erreur moyenne entre les valeurs prédites et les valeurs réelles.
- **MSE (Mean Squared Error)** : Moyenne des carrés des écarts entre les prédictions et la réalité, sensible aux grandes erreurs.
- **MLP** : Réseau de neurones à couches entièrement connectées, adapté aux données statiques.
- **Optuna** : Outil d'optimisation automatique d'hyperparamètres basé sur des méthodes bayésiennes.
- **Optimisation bayésienne** : Stratégie d'optimisation guidée par un modèle probabiliste des performances.
- **Photovoltaïque (PV)** : Technologie convertissant la lumière solaire en électricité.
- **PSO (Particle Swarm Optimization)** : Algorithme d'optimisation inspiré du comportement collectif d'essaims.
- **R² (coefficient de détermination)** : Indicateur de la qualité de prédiction du modèle, proche de 1 quand les résultats sont bons.
- **RNN** : Réseau de neurones traitant les données séquentielles grâce à une mémoire interne.